Minería de datos

Tarea 2: Figuras

Instrucciones generales (aplican a todas las figuras)

- **Rejilla:** activar; estilo --, grosor aprox. 0.7, transparencia ~0.6.
- **Bordes del eje (spines):** visibles en color #222, grosor ~1.2.
- **Marcas y etiquetas (ticks):** legibles, sin amontonamientos; rotar etiquetas si fuese necesario.
- **Tasas/porcentajes:** cuando el eje represente una tasa (p. ej., Defect_Rate), formatear el eje en **%**.
- **Colores/series (consistencia en todo el trabajo):**
    - **Production_Line (Fig 1 , Fig 2):**
        - Line_A #1f77b4 y forma de circulo
        - Line_B #ff7f0e y forma de cuadrado
        - Line_C #2ca02c y forma de triangulo
    - **Shift (Figs 6, 7, 8, 10, 11, 12):**
        - Morning #9467bd (línea sólida),
        - Evening #8c564b (línea discontinua),
        - Night #d62728 (línea punto–raya).

Nota: Los incisos Fig. 12–15 deben realizarse en un solo lienzo con subplots 2×2 (una figura con 6 paneles). Orden sugerido:

Fig. 12	Fig. 13
Fig. 14	Fig. 15

Fig. 1. Producción vs. defectos (dispersión)

Título: Fig. 1: Units_Produced vs Defect_Rate

Eje X: Units_Produced

Eje Y: Defect_Rate

Problema: Determinar si producir más unidades está asociado con una mayor tasa de defectos.

Herramienta: Dispersión (Units_Produced vs Defect_Rate).

Pasos:

- Graficar puntos; diferenciar por Production_Line usando color y forma.
- Formatear ytick como %.
- Activar cuadrícula --.
- Puntos con borde visible y ligera transparencia.
- Leyenda: título “Production_Line” (si se usan colores/formas por línea).

Interpretación: Indicar si hay tendencia positiva/negativa o ausencia de patrón; mencionar outliers.

Ejemplo (otros datos):

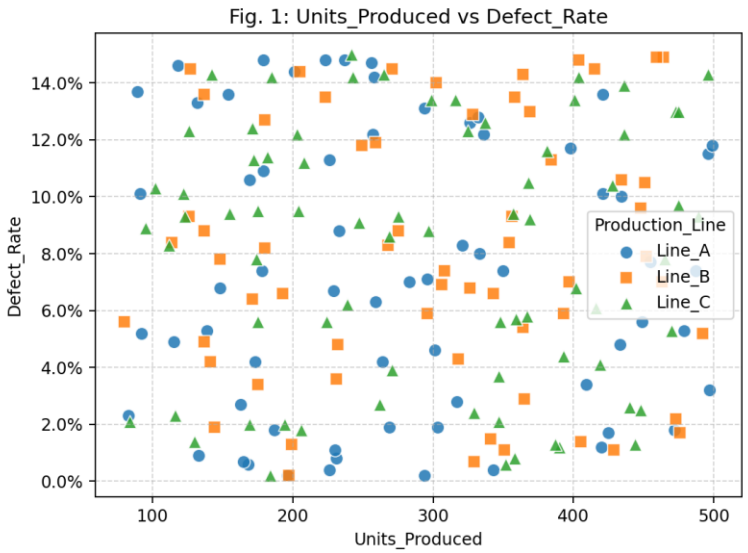


Fig. 2. Energía vs. ingresos (dispersión + tendencia)

Título: Fig. 2: Energía vs Ingresos (r = XX.XX)

Eje X: Energy_Consumption_kWh

Eje Y: Revenue_USD

Problema: Estimar si un mayor consumo de energía conduce a mayores ingresos (efecto de throughput).

Herramienta: Dispersión + línea de tendencia simple.

Pasos:

- Graficar los puntos. Todos los puntos serán círculos de color verde claro.
- Añadir recta de tendencia (OLS) y mostrar r (2 decimales) en el título.
- Activar cuadrícula --.
- Formatear ytick con separador de miles.
- Puntos con borde fino; línea de tendencia en estilo -- y color contrastante.
- Leyenda: “Observaciones” y “Tendencia (OLS)”.

Interpretación: Describir la dirección/fuerza de la relación y posibles outliers.

Ejemplo (otros datos):

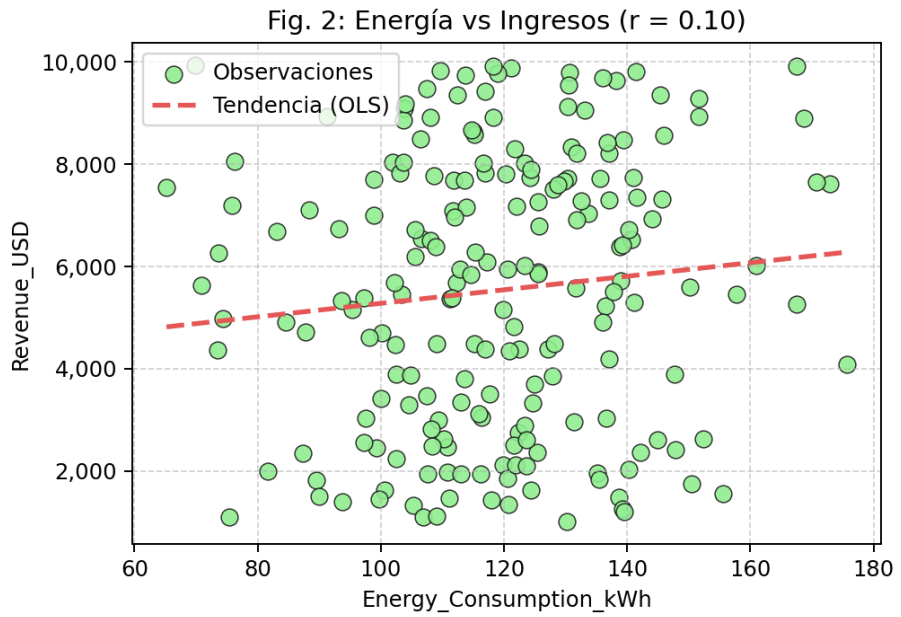


Fig. 3. Distribución de defectos (histograma)

Título: Fig. 3: Distribución de Defect_Rate

Eje X: Defect_Rate

Eje Y: Frecuencia

Problema: Conocer la distribución de la tasa de defectos para priorizar mejoras de calidad.

Herramienta: Histograma de Defect_Rate.

Pasos:

- Elegir ~20 bins de color azul claro y borde azul oscuro.
- Marcar media (línea verde --) y mediana (línea roja -.) y etiquetarlas numéricamente.
- Formatear xtick como %; ytick en enteros.
- Barras con borde; cuadrícula --.
- Leyenda: Media y Mediana.

Interpretación: Indicar si la distribución es sesgada y dónde se concentra.

Ejemplo (otros datos):

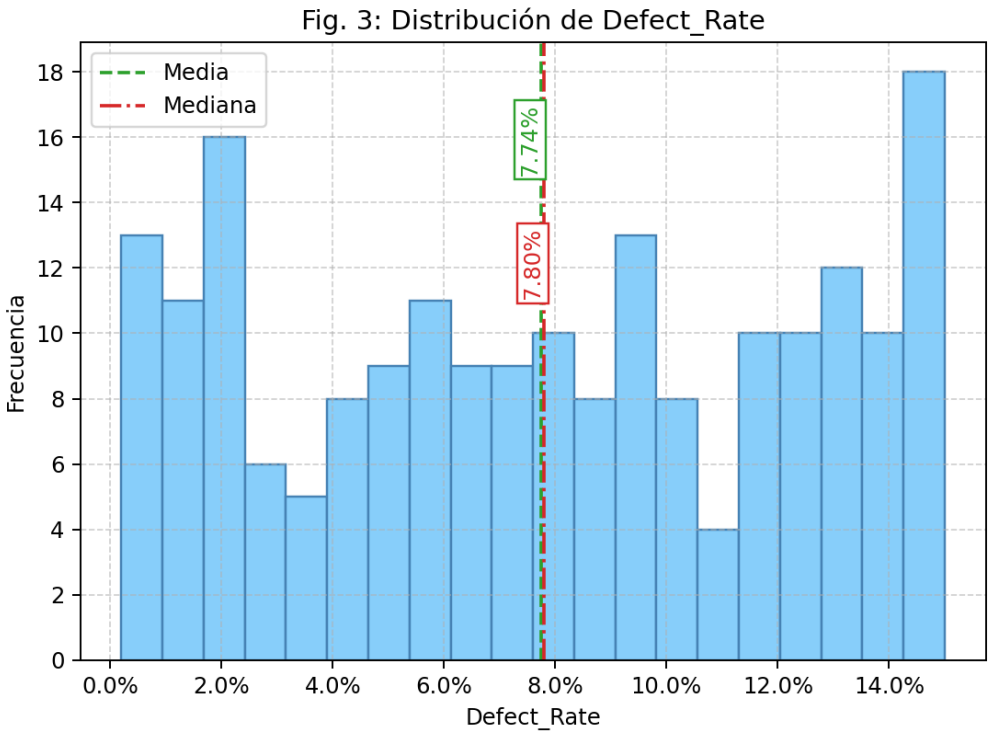


Fig. 4. Tiempos muertos (histograma)

Título: Fig. 4: Distribución de Downtime_Minutes
Eje X: Downtime_Minutes
Eje Y: Frecuencia

Problema: Evaluar si los tiempos de paro se concentran en valores bajos o hay colas largas.
Herramienta: Histograma de Downtime_Minutes.
Pasos:

- Construir el histograma con ~15 bins (barras color #f28e2b, borde #1a1a1a, grosor ~1.2).
- Moda: identificar el bin con mayor frecuencia y trazar una línea vertical verde -- (~1.5) en el centro de ese bin; etiquetar como “Moda (bin)”.
- Colas: calcular P90 (línea azul : ~1.3) y P95 (línea roja -. ~1.3); sombrear la cola derecha a partir de P95 con rojo translúcido.
- (Opcional) Forma suavizada (KDE): añadir la curva de densidad en un eje secundario (y2), línea gris #111 continua (~2.0); no activar cuadrícula en el eje secundario.
- Cuadrícula: activar --, grosor ~0.7, alpha ~0.6.
- Ticks: ytick en enteros; ajustar xtick a rangos útiles (rotar etiquetas si fuera necesario).
- Leyenda: incluir Frecuencia, Moda (bin), P90, P95, Cola derecha y Densidad (KDE) (si se añadió).

Interpretación: Señalar la moda y describir si hay cola derecha (o izquierda) pronunciada; comentar si la distribución luce asimétrica y si es uni o multimodal (apoyándose en la KDE si se graficó).

Ejemplo (otros datos):

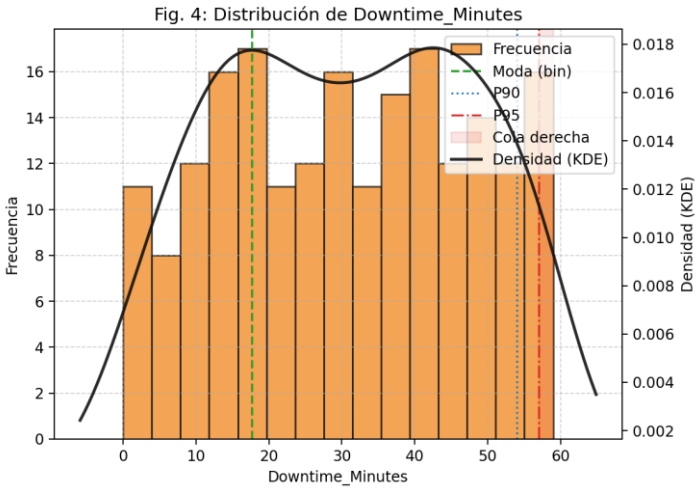


Fig. 5. Productividad por línea (barras + error)

Título: Fig. 5: Productividad promedio por línea (±EE)

Eje X: Production_Line

Eje Y: Units_Produced (promedio)

Problema: Identificar qué línea de producción rinde más en promedio.

Herramienta: Barras del promedio de Units_Produced por Production_Line.

Pasos:

- Incluir barras de error (±1 EE o DE).
- Ordenar las barras por media.
- Añadir etiquetas numéricas encima de cada barra.
- Activar cuadrícula --.
- xtick categórico (rotación si hay traslape); ytick en enteros.
- Leyenda: opcional (aclarar si el error es ±EE o DE).

Interpretación: Ordenar líneas y comentar diferencias.

Ejemplo (otros datos):

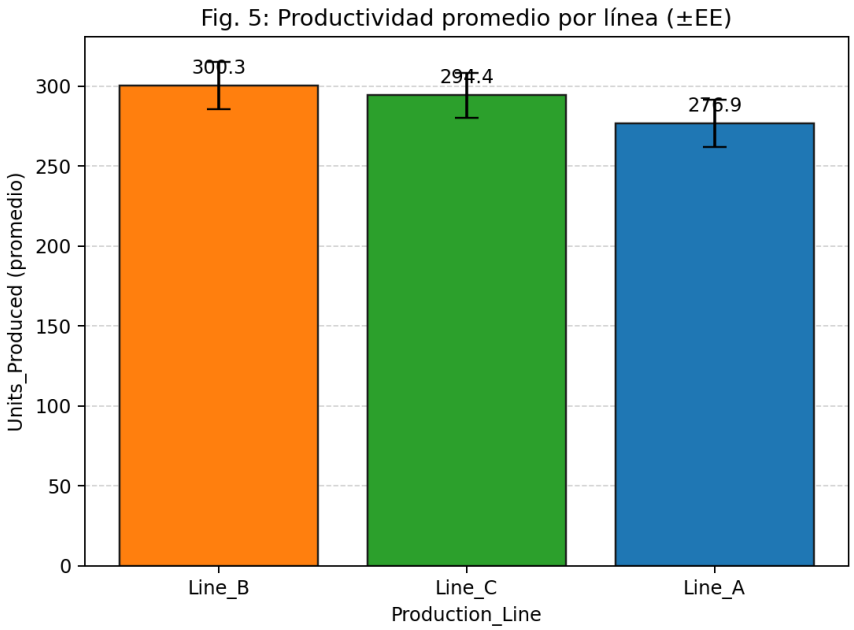


Fig. 6. Ingresos por turno (barras + error)

Título: Fig. 6: Ingresos promedio por turno (±EE)

Eje X: Shift

Eje Y: Revenue_USD (promedio)

Problema: Evaluar si algún turno aporta más ingresos.

Herramienta: Barras del promedio de Revenue_USD por Shift.

Pasos:

- Añadir barras de error (±EE).
- Opcional: normalizar por Units_Produced y reflejarlo en el eje Y y el título.
- Añadir etiquetas numéricas encima de cada barra.
- Activar cuadrícula --.
- xtick categórico (rotación si hace falta); ytick con separador de miles.

Interpretación: ¿Qué turno destaca? ¿Es estadísticamente claro?

Ejemplo (otros datos):

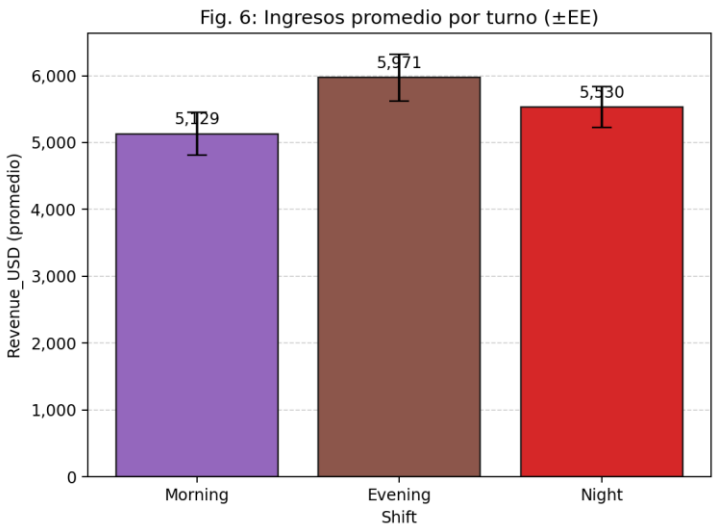


Fig. 7. Costos por turno (boxplot)

Título: Fig. 7: Cost_per_Unit por Shift (Boxplot)

Eje X: Shift

Eje Y: Cost_per_Unit

Problema: Comparar variabilidad de costos entre turnos.

Herramienta: Boxplot de Cost_per_Unit por Shift.

Pasos:

- Usar notch y mostrar outliers; resaltar la mediana.
- Activar cuadrícula --.
- xtick categórico claro; ytick en escala apropiada (decimales si corresponde).

Interpretación: ¿Qué turno es más consistente/caro?

Ejemplo (otros datos):

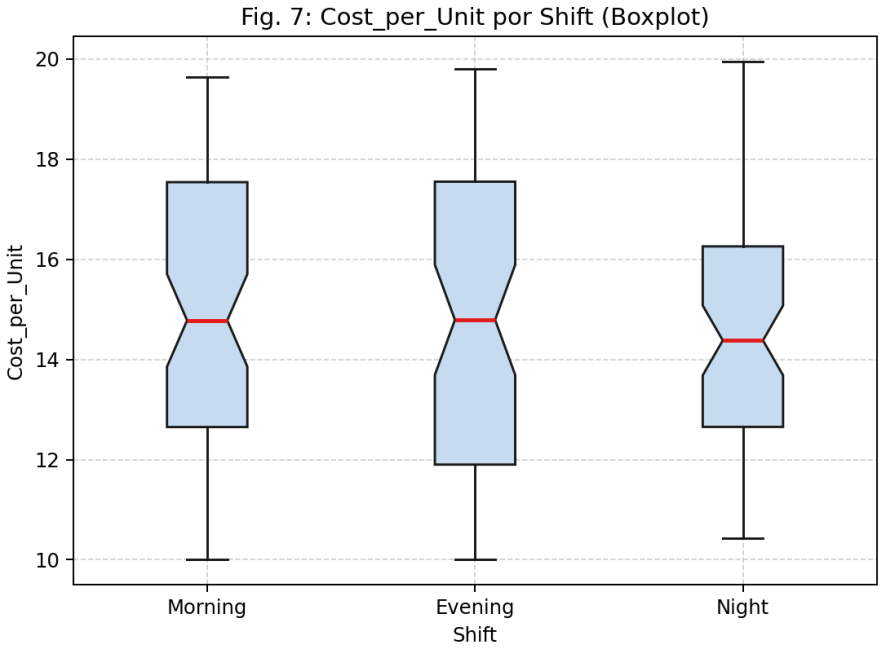


Fig. 8. Calidad por línea y turno (boxplots 2 subgrupos)

Título: Fig. 8: Defect_Rate por línea y turno (Boxplots)

Eje X: Production_Line

Eje Y: Defect_Rate

Problema: Ver si la calidad cambia por línea y, dentro de cada línea, por turno.

Herramienta: Boxplots comparativos de Defect_Rate por Production_Line, subdivididos por Shift.

Pasos:

- Para cada línea, comparar las tres cajas (Morning/Evening/Night) desplazadas lateralmente; colorear por Shift.
- Formatear ytick como %.
- Activar cuadrícula --.
- xtick categórico (alineaciones y rotación si hay traslape).
- Leyenda: título “Shift”.

Interpretación: Mencionar posibles interacciones línea × turno.

Ejemplo (otros datos):

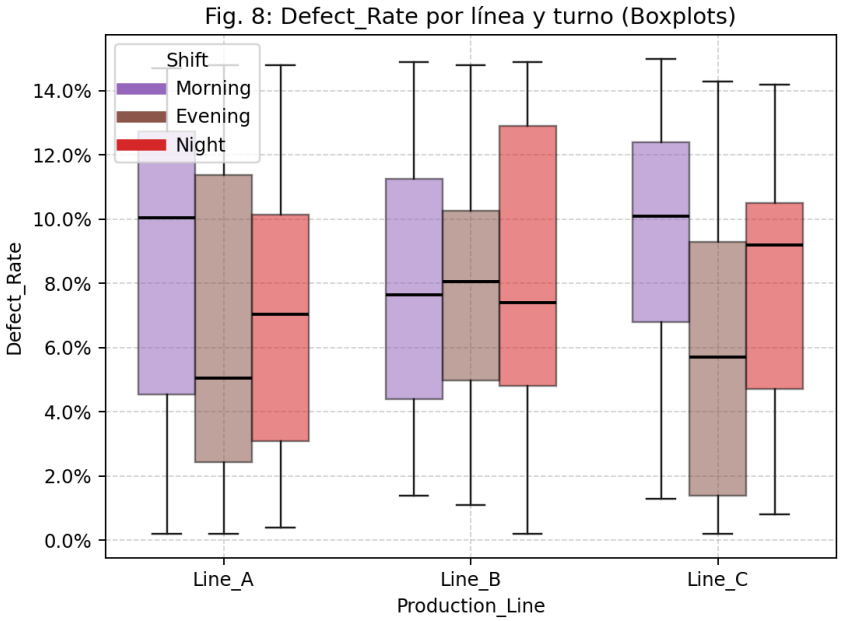


Fig. 9. Densidad de energía (KDE)

Título: Fig. 9: Densidad de Energy_Consumption_kWh

Eje X: Energy_Consumption_kWh

Eje Y: Densidad

Problema: Entender el perfil continuo del consumo de energía.

Herramienta: Curva de densidad de Energy_Consumption_kWh.

Pasos:

- Trazar KDE; opcional: sombrear el área bajo la curva.
- Marcar media (línea --) y mediana (línea -.) con etiquetas.
- Activar cuadrícula --.
- xtick con intervalos legibles; ytick con decimales moderados.
- Leyenda: KDE, Media, Mediana.

Interpretación: ¿Una o varias “panzas” (modas)?

Ejemplo (otros datos):

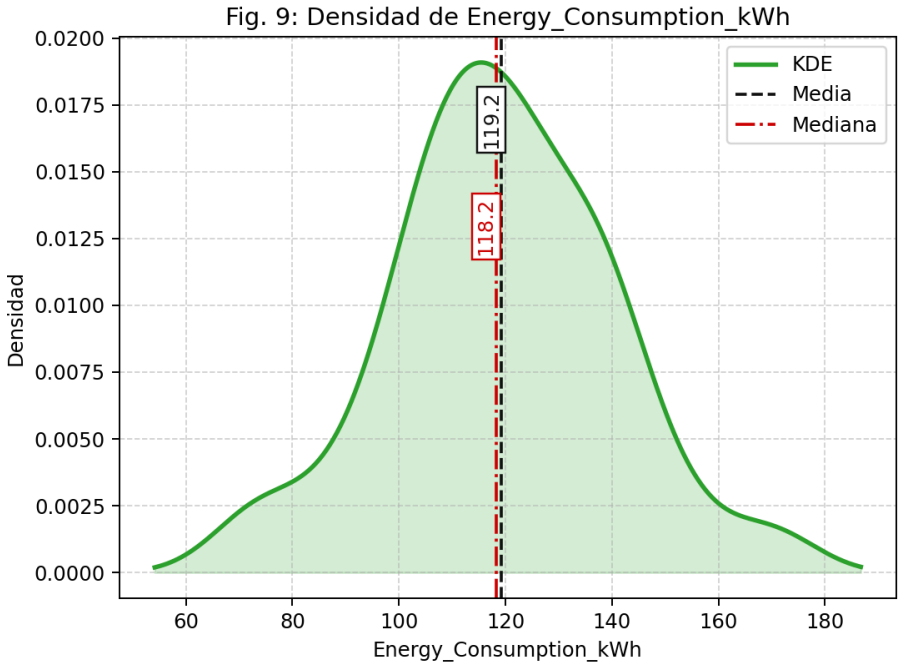


Fig. 10. Mapa de calor (heatmap)

Título: Fig. 10: Heatmap de correlación

Eje X: Variables numéricas

Eje Y: Variables numéricas

Problema: Detectar correlaciones (p. ej., energía con producción, costos con ingresos).

Herramienta: Heatmap de correlación (variables numéricas).

Pasos:

- Calcular la matriz de correlaciones; anotar valores (2 decimales) con contraste adecuado.
- Incluir colorbar titulado “Correlation (r)”.
- xtick/ytick: mostrar nombres de variables; rotar xtick 90° si es necesario.
- Sin cuadrícula adicional sobre el mapa (no aporta aquí).

Interpretación: Señalar 2–3 relaciones clave (aclarando que correlación ≠ causalidad).

Ejemplo (otros datos):

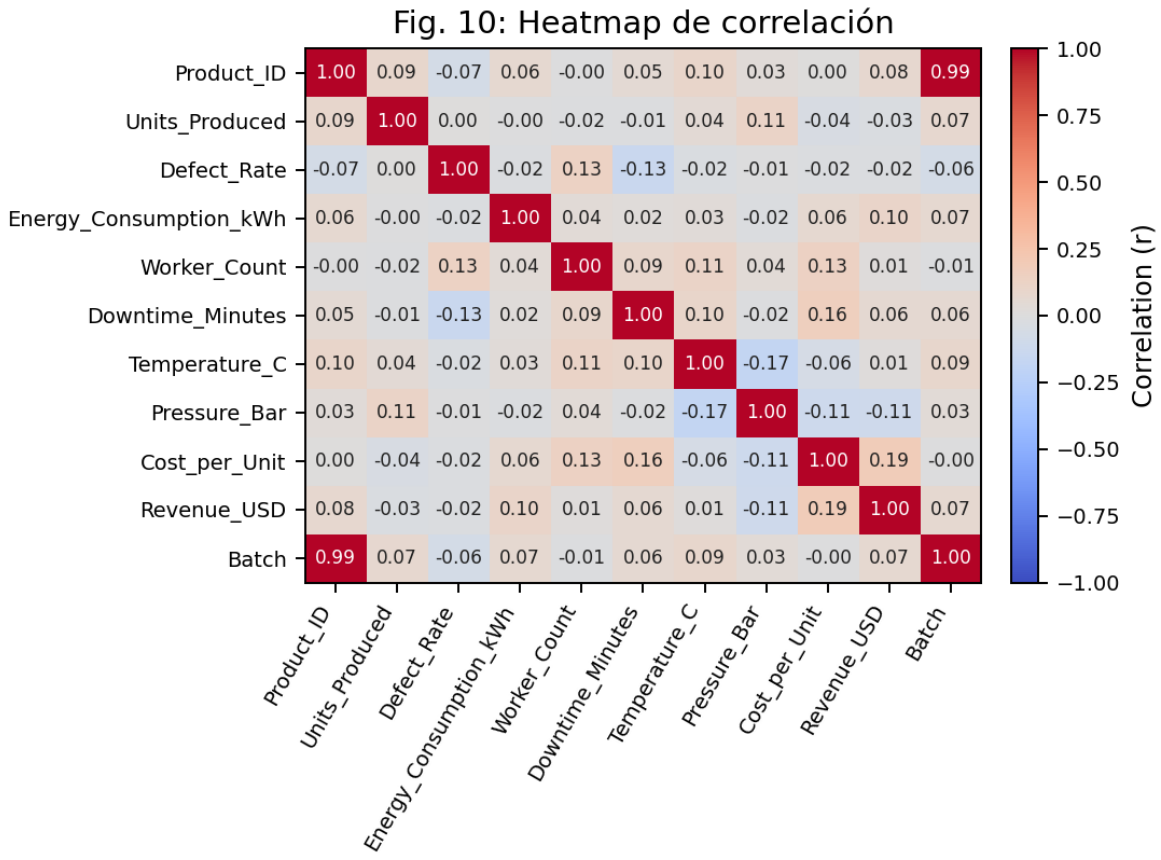


Fig. 11. Tendencias con incertidumbre (líneas + bandas) (sub-figura)

Título: Fig.11: Tendencias Units_Produced por Línea (±EE)

Eje X: Batch

Eje Y: Units_Produced (media)

Problema: Ver tendencias de producción por línea con incertidumbre estimada.

Herramienta: Líneas con bandas de error a través de Batch.

Pasos:

- Para cada Production_Line, trazar la media por Batch.
- Añadir banda de ±EE (o IC95%).
- Superponer todas las series para comparación directa; etiquetar el último punto de cada línea.
- Activar cuadrícula --.
- xtick en enteros (lotes); ytick en intervalos regulares.
- Leyenda: título “Production_Line”.

Interpretación: ¿Qué línea mejora/empeora? ¿Qué tan confiable es (ancho de banda)?

Ejemplo (otros datos):

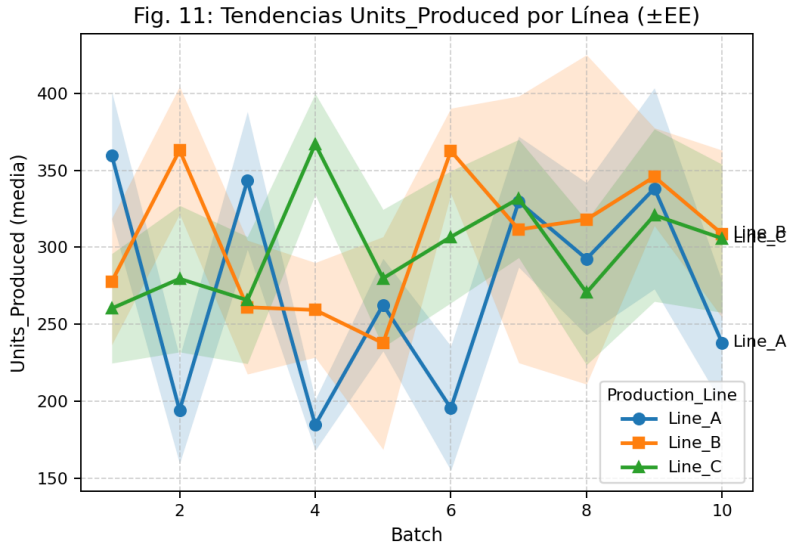


Fig. 12. Densidad de temperatura por turno (sub-figura)

Título: Fig. 12: Densidad de Temperature_C por Shift

Eje X: Temperature_C

Eje Y: Densidad

Problema: Evaluar si las condiciones térmicas difieren entre turnos (posible impacto en calidad).

Herramienta: Densidades (KDE) de Temperature_C separadas por Shift.

Pasos:

- Graficar densidades superpuestas (una por turno) con estilos de línea distintos.
- Activar cuadrícula --.
- xtick centrado en el rango observado; ytick con decimales moderados.
- Leyenda: título “Shift”.

Interpretación: ¿Algún turno opera más frío/caliente?

Ejemplo (otros datos):

Ver al final.

Fig. 13. Producción a lo largo del tiempo (área apilada) (sub-figura)

Título: Fig. 13: Área apilada Units_Produced por Shift (Batch)

Eje X: Batch

Eje Y: Units_Produced (suma)

Problema: Observar la contribución de cada turno al volumen total a través de lotes.

Herramienta: Área apilada de Units_Produced por Shift a lo largo de Batch.

Pasos:

- Definir Batch = (Product_ID-1)//20 + 1; agregar por lote/turno y apilar.
- Activar cuadrícula --.
- xtick en enteros (lotes consecutivos); ytick en enteros/centenas según escala.
- Colocar la leyenda en zona que no tape datos (título “Shift”).

Interpretación: ¿Qué turno sostiene el pico/valle de producción?

Ejemplo (otros datos):

Ver al final.

Fig. 14. Mezcla de turnos por línea (barras apiladas) (sub-figura)

Título: Fig. 14: Composición de Turnos por Línea (%)

Eje X: Production_Line

Eje Y: % de registros

Problema: Conocer la composición de turnos dentro de cada línea para balance operativo.

Herramienta: Barras apiladas (conteo) de Shift dentro de Production_Line.

Pasos:

- Normalizar a porcentajes (recomendado).
- Etiquetar internamente segmentos ≥ 8% (sin decimales).
- Segmentos con borde fino; eje Y en %; rejilla --; spines #222.
- Leyenda: título Shift.

Interpretación: ¿Qué líneas dependen más de cierto turno?

Ejemplo (otros datos):

Ver al final.

Fig. 15. Panorama multivariable (vista dentro del grid) (sub-figura)

Título: Fig. 15: Units_Produced vs Revenue_USD (por línea)

Eje X: Units_Produced

Eje Y: Revenue_USD

Problema: Explorar patrones conjuntos entre producción e ingresos por línea.

Herramienta: Dispersión por Production_Line.

Pasos:

- Graficar puntos por línea con colores/markers consistentes.
- Añadir una tendencia global (opcional).
- Activar cuadrícula --.
- xtick en intervalos útiles; ytick con separador de miles.
- Leyenda: título “Production_Line” (y “Tendencia” si se incluye).

Interpretación: Mencionar relaciones visibles u outliers por línea.

Ejemplo (otros datos):

Ver al final.

Figs. 12–15: Resumen de distribución, producción y relación

Fig. 12: Densidad de Temperature_C por Shift

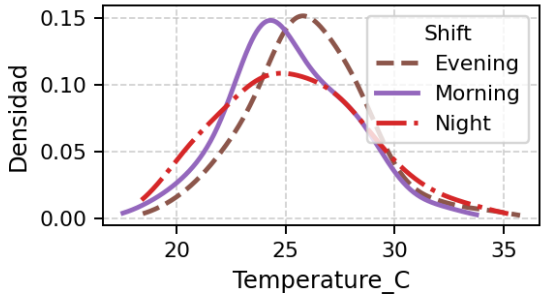


Fig. 13: Área apilada Units_Produced por Shift (Batch)

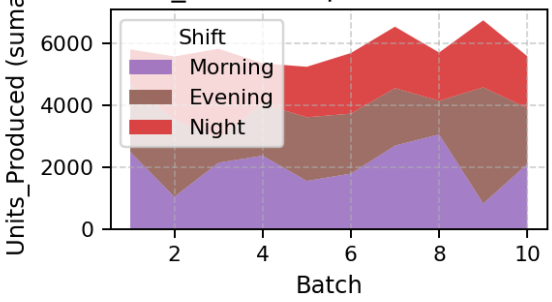


Fig. 14: Composición de Turnos por Línea (%)

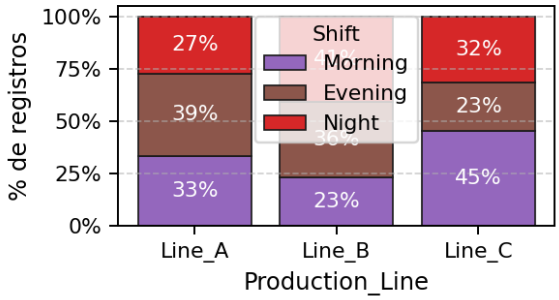


Fig. 15:Units_Produced vs Revenue_USD (por línea)

