Práctica: Clasificación de usuarios mediante análisis de redes

Dataset: Twitch Social Networks – Stanford SNAP. Utilizar la red PT (Portugal), con 1,912 usuarios y 31,299 conexiones, relativamente pequeña y con un target binario.

metromaps.stanford.edu

+1

Problema: Una plataforma de streaming desea investigar si la posición de un usuario dentro de su red social permite predecir si transmite contenido para adultos.

Datos:

- Nodos: Usuarios de Twitch.
- Aristas: Conexiones entre usuarios, obtenidas directamente de las dos columnas del archivo PT_edges.csv.
- Target: mature (0 = no, 1 = sí), asociado a cada usuario mediante PT_target.csv.
- Grafo: No dirigido y sin pesos.

Actividades

1. Construir el grafo con NetworkX utilizando las dos columnas de conexiones.
2. Dibujar la red con todos los nodos en gris y posteriormente coloreados según el target.
3. Calcular degree, betweenness, closeness, eigenvector centrality y clustering coefficient.
4. Generar cinco grafos adicionales, coloreando los nodos según cada métrica, manteniendo las mismas posiciones.
5. Identificar los cinco nodos con mayor valor de cada métrica e interpretar sus diferencias.
6. Dividir los nodos en training (80%) y testing (20%), de manera estratificada.
7. Entrenar y comparar un mismo clasificador (Random Forest) utilizando dos representaciones independientes:
    - Modelo A — Matriz de adyacencia: Cada usuario se representa mediante una fila de la matriz binaria que indica sus conexiones con los nodos de training.
    - Modelo B — Distancias entre nodos: Cada usuario se representa mediante sus distancias de camino más corto hacia los nodos de training. Las distancias infinitas deberán tratarse explícitamente.
8. Evaluar ambos modelos en testing mediante accuracy, F1-score y matriz de confusión.