Práctica: Clasificación de usuarios mediante análisis de redes

Dataset: Twitch Social Networks — Portugal (PT)

Se construyó una red no dirigida y sin pesos con el archivo musae_PTBR_edges.csv y se asignó la etiqueta binaria mature mediante la columna new_id del archivo musae_PTBR_target.csv. Para el análisis predictivo se utilizó únicamente mature como variable objetivo; las demás columnas del archivo target no se utilizaron como predictores.

1. Construcción y descripción de la red

Indicador	Resultado
Nodos (usuarios)	1,912
Aristas (conexiones)	31,299
Componentes conexas	1
Densidad	0.0171
Grado medio	32.74
Coeficiente de clustering medio	0.3199
Diámetro	7
mature = 0	1,251 (65.4%)
mature = 1	661 (34.6%)

La red contiene un solo componente conexo, por lo que todos los usuarios pueden alcanzarse mediante algún camino. El grado medio es de aproximadamente 32.74 conexiones por usuario. La densidad relativamente baja indica que solo una fracción pequeña de todas las conexiones posibles está presente.

2. Visualización de la red

Primero se dibujó la red con todos los nodos en gris y después se coloreó según mature (azul = 0; rojo = 1). Las visualizaciones de las cinco métricas mantienen la misma distribución espacial calculada con spring_layout (semilla 42), lo que facilita comparar las zonas de la red.

Figura 1. Todos los nodos en gris

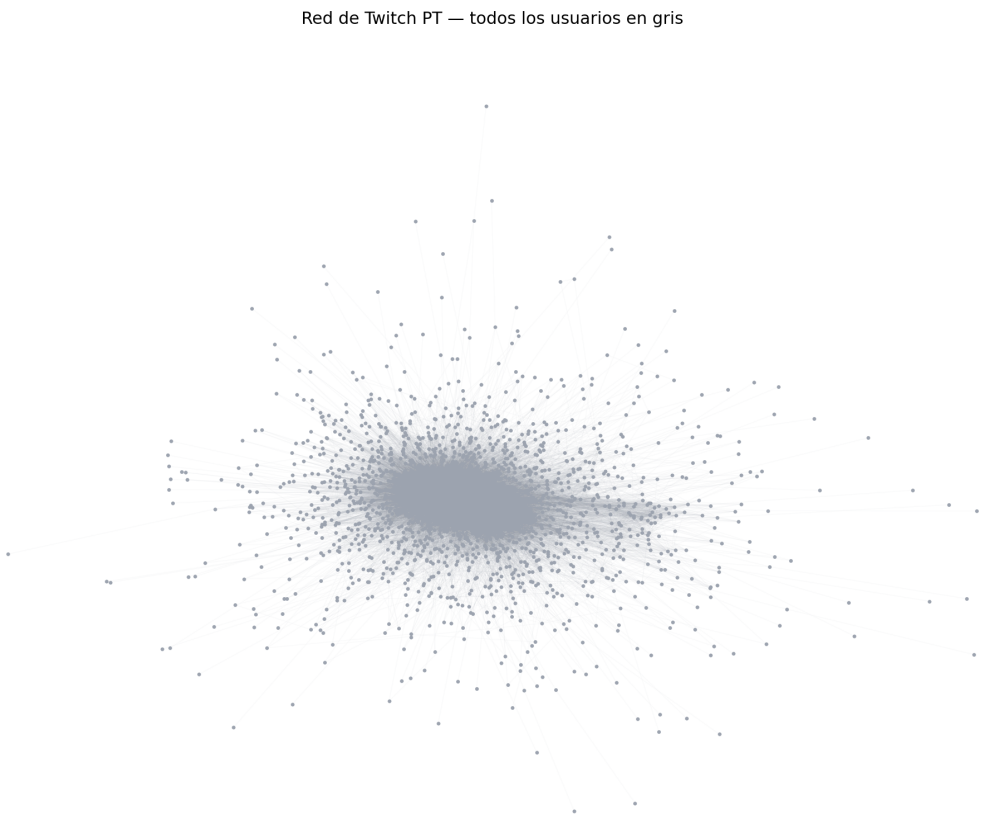
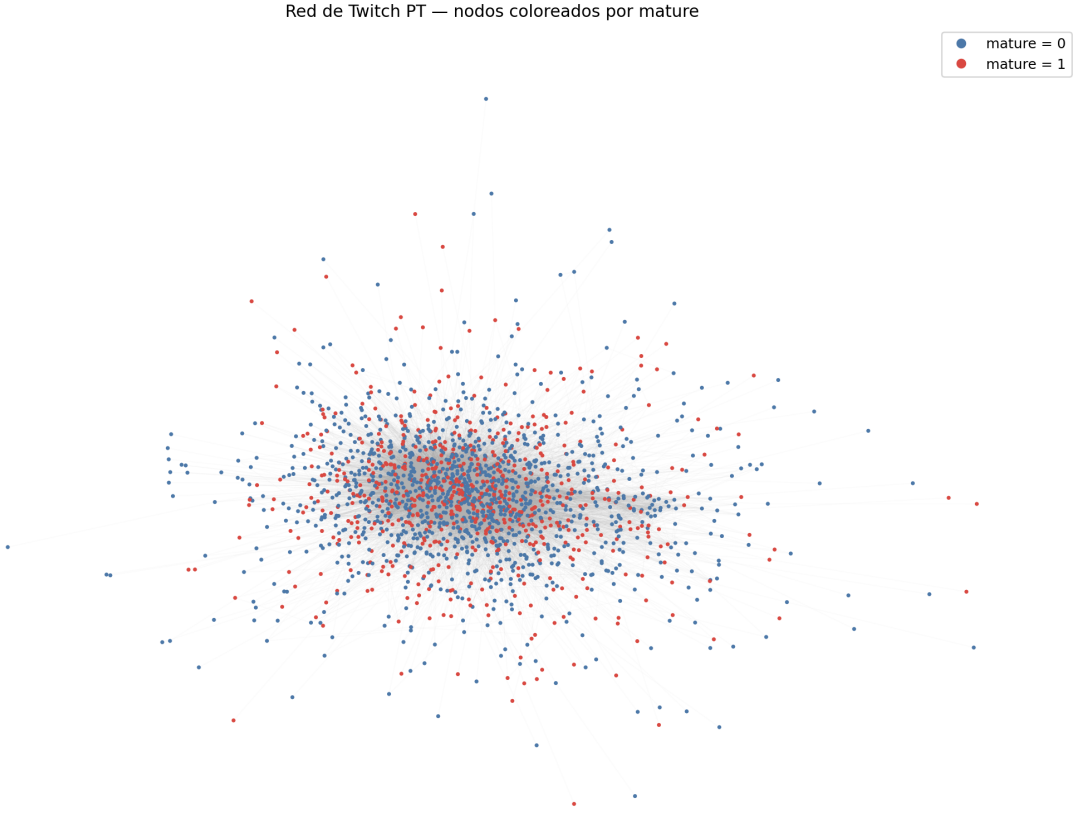


Figura 2. Nodos coloreados por mature



3. Centralidades y coeficiente de clustering

Se calcularon degree centrality, betweenness centrality, closeness centrality, eigenvector centrality y clustering coefficient. En los grafos siguientes, los colores representan valores bajos o altos de la métrica indicada; la posición de los nodos se conserva.

Figura 3. Degree centrality

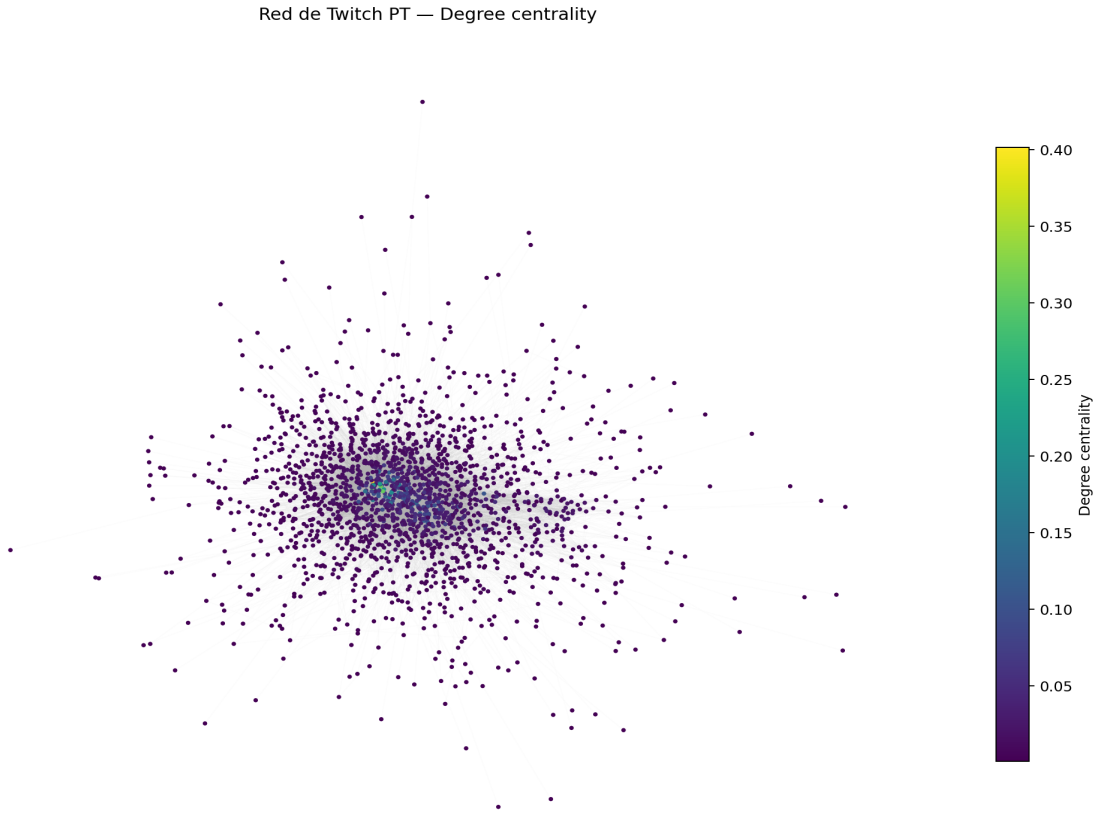


Figura 4. Betweenness centrality

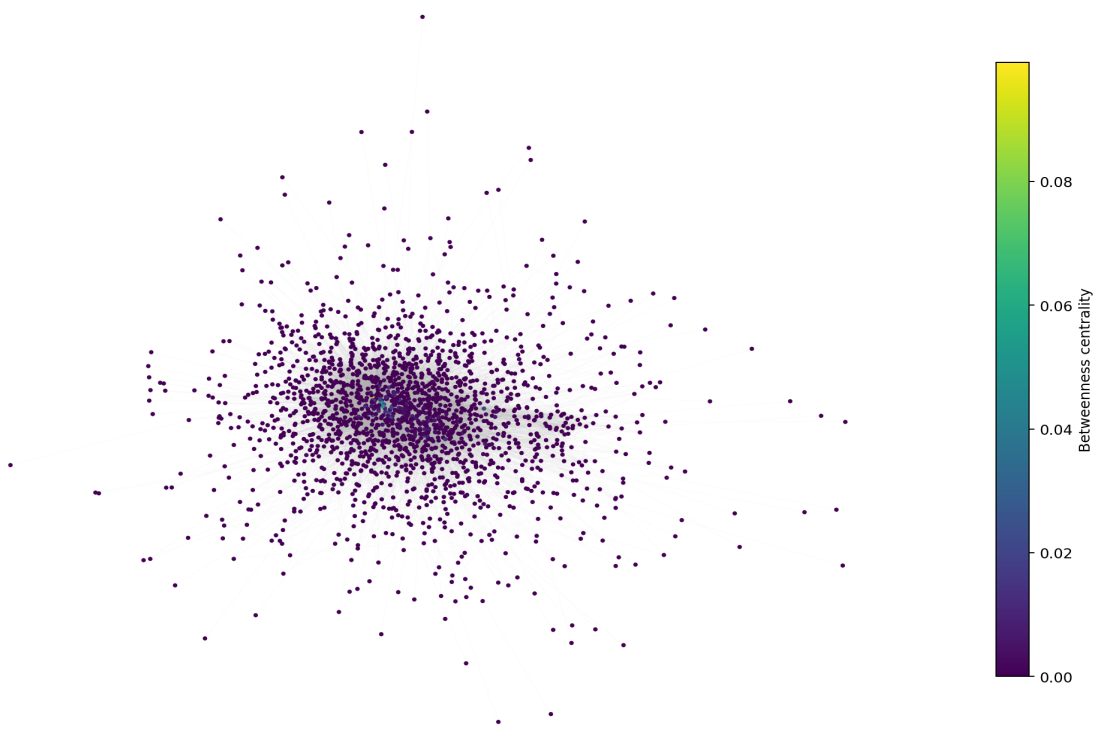

Red de Twitch PT — Betweenness centrality
Betweenness centrality
0.00
0.02
0.04
0.06
0.08

Figura 5. Closeness centrality

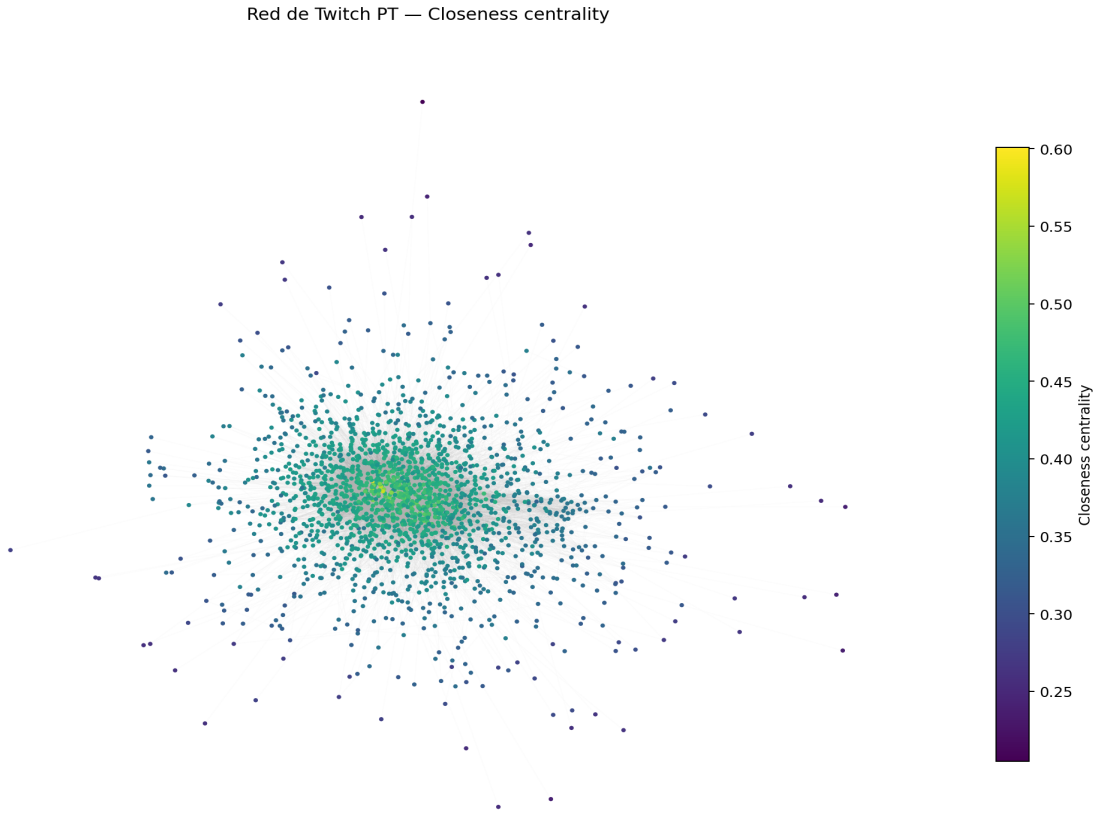


Figura 6. Eigenvector centrality

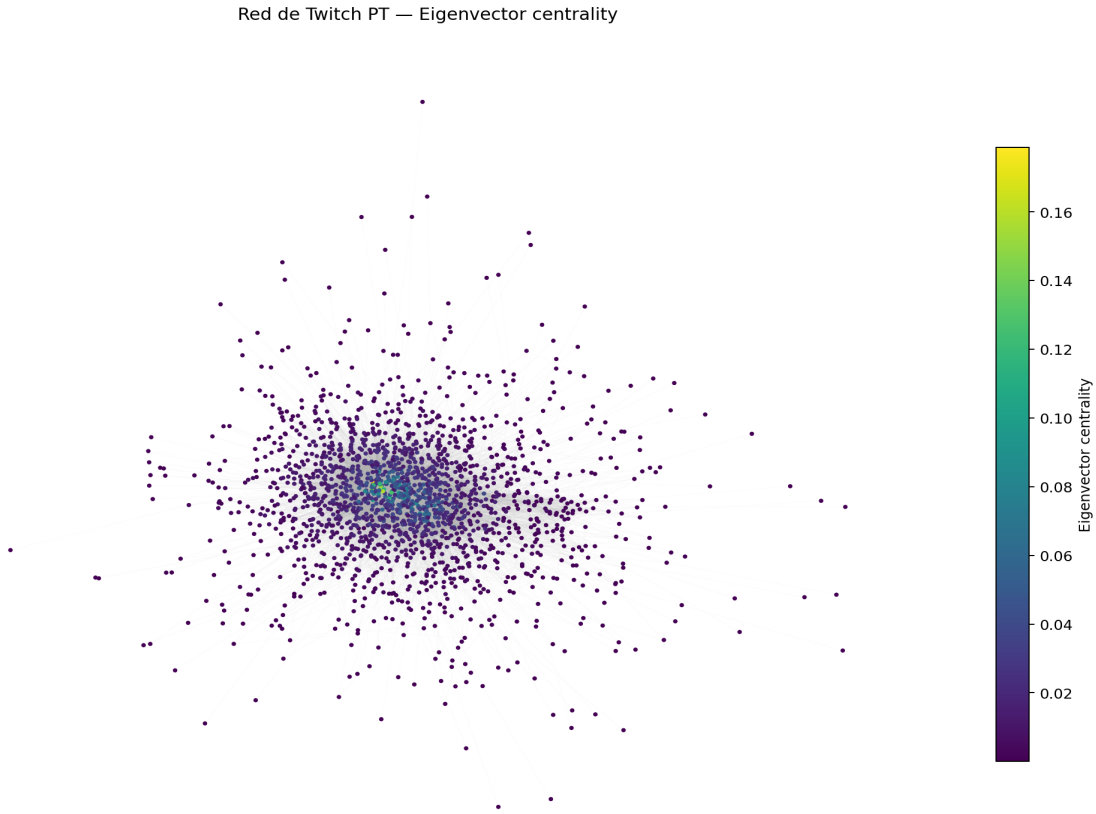
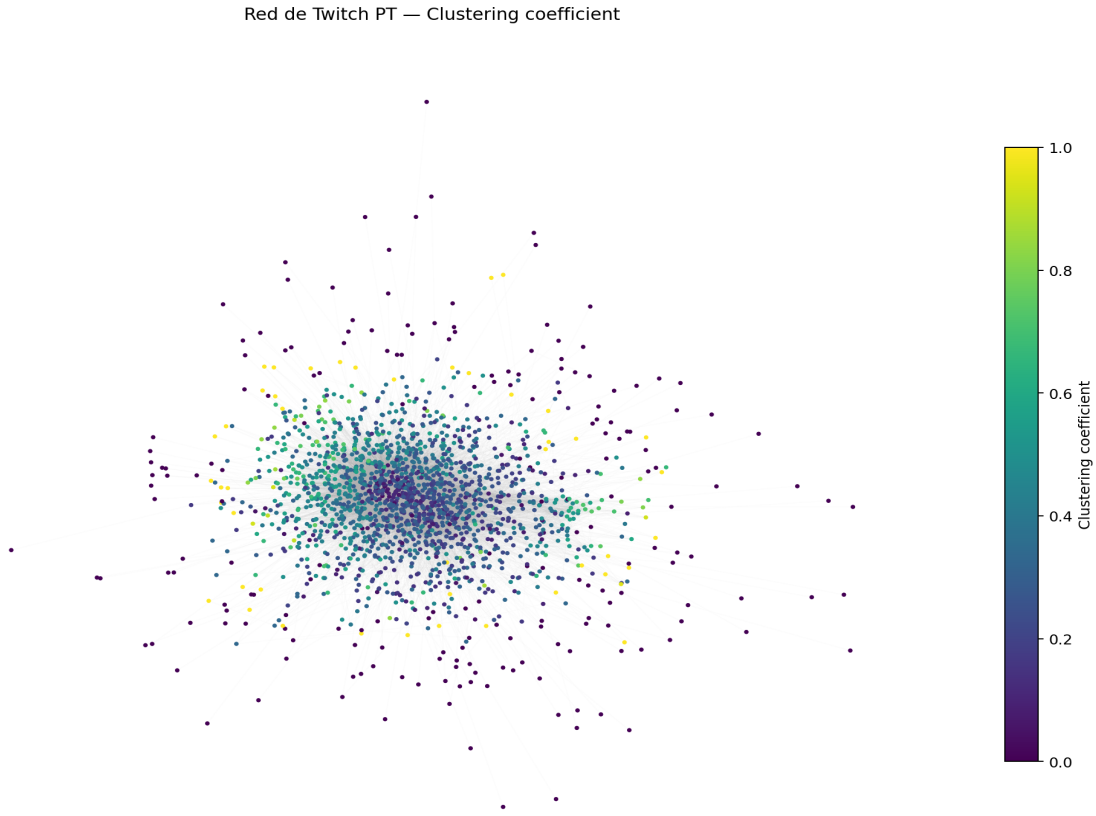

Red de Twitch PT — Eigenvector centrality
Eigenvector centrality
0.16
0.14
0.12
0.10
0.08
0.06
0.04
0.02

Figura 7. Clustering coefficient



4. Cinco nodos con mayor valor por métrica

La columna mature indica la etiqueta del usuario (0 = no, 1 = sí). El valor de la métrica se muestra con seis decimales cuando corresponde.

Degree centrality

Pos.	Nodo	mature	Valor	Grado
1	127	0	0.401361	767
2	1476	0	0.312925	598
3	290	0	0.308739	590
4	1297	0	0.307169	587
5	467	0	0.304553	582

Betweenness centrality

Pos.	Nodo	mature	Valor	Grado
1	127	0	0.099261	767
2	1476	0	0.054895	598
3	1297	0	0.050421	587
4	290	0	0.050112	590
5	467	0	0.043825	582

Closeness centrality

Pos.	Nodo	mature	Valor	Grado
1	127	0	0.600943	767
2	1297	0	0.568412	587
3	467	0	0.565050	582
4	290	0	0.559590	590
5	1476	0	0.559426	598

Eigenvector centrality

Pos.	Nodo	mature	Valor	Grado
1	127	0	0.178782	767
2	1297	0	0.158671	587
3	467	0	0.157242	582
4	290	0	0.151505	590
5	1476	0	0.145764	598

Clustering coefficient

Pos.	Nodo	mature	Valor	Grado
1	32	0	1.000000	3
2	727	0	1.000000	3

Pos.	Nodo	mature	Valor	Grado
3	740	0	1.000000	2
4	1898	0	1.000000	2
5	1880	1	1.000000	5

Interpretación de las diferencias

• **Degree:** identifica a quienes tienen más conexiones directas. El nodo 127 lidera con 767 conexiones (degree centrality ≈ 0.4014), por lo que es el usuario más conectado en términos directos.

• **Betweenness:** mide cuánto aparece un nodo en los caminos mínimos entre otros pares. El nodo 127 también ocupa el primer lugar; puede actuar como puente importante entre distintas zonas de la red.

• **Closeness:** favorece a usuarios con distancias cortas hacia el resto. El nodo 127 vuelve a destacar, señal de que combina muchas conexiones con una posición cercana al resto de la red.

• **Eigenvector:** da más importancia a las conexiones con usuarios que también son importantes. El nodo 127 vuelve a ser primero, seguido por nodos con grados altos; no solo importa cuántas conexiones hay, sino a quién conectan.

• **Clustering coefficient:** mide qué proporción de las conexiones posibles entre los vecinos de un nodo realmente existe. Los primeros puestos llegan a 1.0, pero algunos tienen solo 2 o 3 vecinos; por eso un valor alto no significa necesariamente gran influencia o muchas conexiones.

5. Clasificación con Random Forest

Se realizó una división estratificada 80/20 con random_state=42: 1529 nodos para entrenamiento y 383 para prueba. Ambos modelos utilizan RandomForestClassifier con 300 árboles y random_state=42. La etiqueta mature se mantuvo fuera de las características de entrada.

Modelo A — Matriz de adyacencia

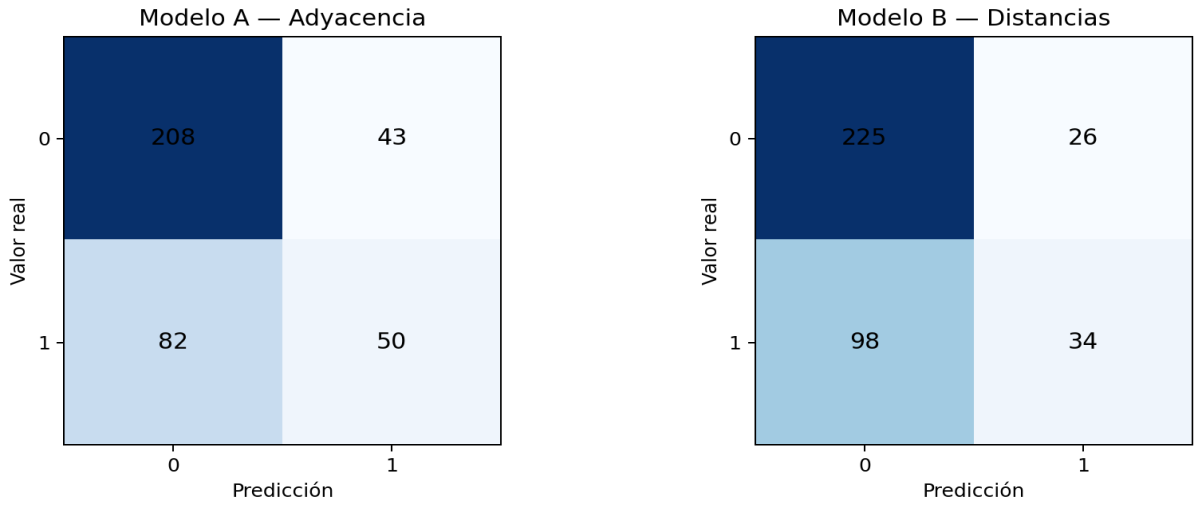
Cada usuario se representa por una fila con sus conexiones binarias hacia los 1,529 nodos del conjunto de entrenamiento. Para evitar cambiar la definición entre modelos, ambos utilizan exactamente la misma partición de usuarios.

Modelo B — Distancias de camino más corto

Cada usuario se representa por sus distancias mínimas a los mismos nodos de entrenamiento. El código detecta distancias infinitas y las sustituye por el máximo valor finito más uno (8). En este grafo todas las distancias resultaron finitas (0 infinitas), pero la regla queda implementada explícitamente.

6. Resultados en testing

Modelo	Accuracy	F1 (mature=1)	TN	FP	FN	TP
Modelo A — Adyacencia	0.6736	0.4444	208	43	82	50
Modelo B — Distancias	0.6762	0.3542	225	26	98	34



En las matrices, las filas representan la clase real (0, 1) y las columnas la predicción (0, 1). TN = verdaderos negativos; FP = falsos positivos; FN = falsos negativos; TP = verdaderos positivos.

Comparación

El Modelo B obtiene una accuracy ligeramente superior (0.6762 frente a 0.6736), pero el Modelo A consigue mejor F1 para mature=1 (0.4444 frente a 0.3542). Como el objetivo es detectar la clase positiva, el Modelo A resulta más equilibrado para esa clase: identifica 50 de los 132 usuarios positivos del conjunto de prueba, mientras que el Modelo B identifica 34. Ambos modelos presentan dificultades para recuperar la clase mature=1, por lo que la accuracy por sí sola no describe completamente el rendimiento.

7. Conclusiones

Las métricas de red describen aspectos distintos de la posición social: conexiones directas (degree), intermediación en caminos (betweenness), cercanía global (closeness), conexión con nodos importantes (eigenvector) y cohesión local entre vecinos (clustering). Los nodos 127, 1476, 290, 1297 y 467 dominan varias métricas de centralidad global, mientras que los máximos de clustering corresponden a nodos con vecindarios muy cerrados y no necesariamente grandes. En la clasificación, las distancias no mejoran el F1 de la clase positiva respecto a la adyacencia. Por tanto, con esta partición y estos parámetros, la matriz de adyacencia es la mejor de las dos representaciones si se prioriza identificar usuarios con mature=1. Los resultados muestran asociación predictiva limitada y no implican causalidad.

Archivos complementarios: notebook reproducible, script Python, gráficas, tabla completa de centralidades, top 5 por métrica y resultados de evaluación.