Minería de datos

Tarea 3: Pruebas estadísticas.

En minería de datos, la elección de una prueba estadística adecuada depende directamente del tipo de variables con las que se trabaja y de la pregunta de investigación que se desea responder. No todas las pruebas sirven para todos los casos, ya que algunas requieren supuestos de normalidad, homogeneidad de varianzas o la naturaleza de los datos (continuos, categóricos, ordinales o de conteo).

En este trabajo se busca poner en práctica diferentes pruebas estadísticas utilizando bases de datos descargadas de Kaggle, analizando relaciones entre variables continuas, categóricas y ordinales. Para cada caso se planteará una hipótesis nula (H0) y una hipótesis alternativa (H1), se seleccionará la prueba más adecuada de acuerdo con la distribución de los datos, y se interpretarán los resultados en función del valor p obtenido.

De esta manera, se desarrollará un criterio claro para elegir correctamente la técnica estadística, fundamentando la decisión en la naturaleza de las variables y el objetivo del análisis.

---

1) SALIDA CONTINUA – ENTRADA CONTINUA

Aquí se busca evaluar si existe correlación entre dos variables continuas (por ejemplo: altura y peso, edad y presión arterial, horas de estudio y calificación).

1.1. Descargar un dataset de Kaggle que tenga al menos dos variables numéricas continuas.

I. Definir brevemente en qué consiste (ejemplo: un dataset de salud donde se registran altura y peso de pacientes).
II. Número de columnas y de filas.
III. Número de columnas numéricas y categóricas; si hay de otro tipo (ejemplo: fechas), puede mencionarlas.

1.2. Explicar qué es lo que se busca demostrar:

I. Plantear la pregunta de investigación (ejemplo: ¿la altura está correlacionada con el peso de las personas?).
II. Formular la hipótesis nula (H0): No existe correlación entre la variable A y la variable B.
III. Formular la hipótesis alternativa (H1): Sí existe correlación entre la variable A y la variable B.

1.3. Mostrar resultados de la prueba de normalidad en ambas variables (por medio de histogramas y QQ-Plot):

I. Prueba de normalidad para la variable A (ejemplo: altura).
II. Prueba de normalidad para la variable B (ejemplo: peso).
III. Conclusión: si ambas son normales o no.

1.4. Indicar la prueba estadística aplicada:

I. Indicar prueba usada: correlación de Pearson o correlación de Spearman.
II. Justificación: Se aplicó Pearson porque ambas variables cumplen normalidad o Se aplicó Spearman porque al menos una variable no cumple normalidad.

1.5. Significancia estadística:

I. Reportar el valor p obtenido.
II. Interpretar el valor p en contexto: “Si la hipótesis nula fuera cierta (es decir, que no existe correlación entre A y B), la probabilidad de observar un coeficiente de correlación como el obtenido es de 100 × p %.”

1.6. Explicar si se aceptó o rechazó H0:

I. Si p ≥ 0.05 → no se rechaza H0 | Si p < 0.05 → se rechaza H0.

1.7. Resumir los hallazgos de la correlación:

I. Reportar el coeficiente de correlación (r de Pearson o rho de Spearman).
II. Indicar si la correlación es positiva o negativa.
III. Indicar si la correlación es fuerte, moderada o débil (usando criterios como: |r| < 0.3 débil, 0.3–0.6 moderada, >0.6 fuerte).
IV. Ejemplo de redacción: Existe una correlación positiva moderada entre la altura y el peso (r = 0.52, p = 0.004), por lo cual se rechaza H0.

1.8. Visualización de resultados:

I. Graficar diagrama de dispersión de A vs B.
II. Añadir línea de regresión con bandas de confianza del 95%.
III. Señalar gráficamente si la relación parece lineal o no.

---

2) SALIDA CONTINUA - ENTRADA CATEGÓRICA

En este caso se busca evaluar si una variable continua (ej. salario, puntaje en un examen) puede ser explicada o predicha por una variable categórica (ej. nivel educativo, país, tipo de dieta).

2.1. Descargar un dataset que contenga al menos una columna categórica (con 2 o más niveles) y otra continua:

I. Definir brevemente en que consiste (ejemplo: deportes donde se compara el desempeño de equipos)
II. Número de columnas y de filas.
III. Número de columnas numéricas y categóricas, si hay de otro tipo (ejemplo: fechas), puede mencionarlas.

2.2. Explicar qué es lo que se busca demostrar (ejemplo: las personas de Europa tienen más altura que las de América):

I. Plantear pregunta de investigación.
II. Formular la hipótesis nula (H0).
III. Formular la hipótesis alternativa (H0)

2.3. Mostrar resultados de la prueba de normalidad y homogeneidad de vairanzas:

I. Prueba de normalidad.
II. Prueba de homogeneidad de varianzas.

2.4. Indicar la prueba estadística aplicada:

I. Indicar prueba usada (t-test o Mann Whitney).
II. ¿Por qué aplico esta prueba? (normalidad vs no normalidad)

2.5. Significancia estadística:

I. Valor p obtenido
II. Interpretar dicho valor p: "si la hipótesis nula fuera cierta (indicar aquí cuál es su hipótesis nula), la probabilidad de observar los datos obtenidos es "100*Valor_p, por ciento". Ejemplo: si p=0.05, entonces 100*0.05=5%.

2.6. Explicar si se aceptó o rechazó H0.

2.7. Resumir si los promedios de los grupos difieren significativamente y en qué magnitud/dirección:

I. Calcular el promedio de cada grupo.
II. Indicar cual es mayor y menor
III. Cual es la diferencia de sus promedios
IV. Indicar si esta diferencia es significativa basada en el valor p. Ejemplo, la media del grupo A (0.6) es 0.5 menor que la del grupo B (1.1), significativamente (p=0.006).

2.8. Realizar diagramas de caja (boxplots) para ver la distribución de la variable continua en cada grupo

(Nota: Este caso se parece al 4, pero aquí se plantea cómo "la categórica explica a la continua", es decir, análisis desde la perspectiva inversa).

---

3) SALIDA CATEGÓRICA - ENTRADA CATEGÓRICA

En este escenario se busca evaluar si existe relación o independencia entre dos variables categóricas (ej. "fuma/no fuma" vs "enfermo/sano", "tipo de transporte" vs "nivel socioeconómico").

3.1. Descargar un dataset que contenga al menos dos variables categóricas:

I. Definir brevemente en qué consiste (ejemplo: un dataset de salud donde se registra "fuma/no fuma" y "enfermo/sano").
II. Número de columnas y de filas.
III. Número de columnas categóricas (mínimo dos para este análisis) y si hay de otro tipo (numéricas, fechas), mencionarlas.

3.2. Explicar qué es lo que se busca demostrar:

I. Plantear la pregunta de investigación (ejemplo: ¿existe asociación entre el hábito de fumar y la presencia de enfermedad?).

II. Formular la hipótesis nula (H0): No existe asociación entre las dos variables categóricas, son independientes.
III. Formular la hipótesis alternativa (H1): Sí existe asociación significativa entre las dos variables categóricas.

3.3. Construir tabla de contingencia:

I. Elaborar tabla cruzada con las dos variables categóricas (ejemplo: filas = "fuma/no fuma", columnas = "enfermo/sano").
II. Mostrar frecuencias observadas en cada celda.
III. Señalar conteos esperados (útil para decidir entre Chi-cuadrado y Fisher).

3.4. Indicar la prueba estadística aplicada:

I. Indicar prueba usada: Chi-cuadrado de independencia o prueba exacta de Fisher.
II. Justificación: Se aplicó Chi-cuadrado porque los conteos esperados en todas las celdas fueron ≥ 5 o Se aplicó Fisher porque había celdas con valores esperados menores a 5.

3.5. Significancia estadística:

I. Reportar el valor p obtenido.
II. Interpretar el valor p en contexto:
Ejemplo "Si la hipótesis nula fuera cierta (es decir, que las variables son independientes), la probabilidad de observar una asociación tan extrema como la encontrada es de 100 × p %."

3.6. Explicar si se aceptó o rechazó H0:

I. Si p ≥ 0.05 → no se rechaza H0 | Si p < 0.05 → se rechaza H0.

3.7. Resumir la fuerza y dirección de la asociación:

Calcular una medida de asociación:
Tablas 2×2 → Phi (ϕ).
I. Tablas mayores → Cramer's V.
II. Interpretar el coeficiente (ejemplo: V = 0.28 → asociación débil).
III. Resumir en palabras: Existe una asociación significativa y débil entre fumar y estar enfermo (Chi^2 = 12.3, p = 0.002, Cramer's V = 0.28).

3.8. Visualización de resultados:

I. Presentar la tabla de contingencia como tabla de frecuencias.
II. En caso de muchas categorías, usar un heatmap (mapa de calor) de frecuencias o de residuos estandarizados para identificar qué combinaciones contribuyen más a la asociación.

---

4) SALIDA CATEGÓRICA - ENTRADA CONTINUA

Aquí el interés es ver si una variable continua (ej. nivel de colesterol, edad, ingresos, etc.) está relacionada con una variable categórica (ej. "fumador/no fumador", "sexo", "aprobó/no aprobó").

4.1. Seleccionar un dataset de Kaggle que contenga: Una variable categórica binaria (ej. fumador sí/no) y una variable continua (ej. colesterol, edad, ingresos, etc.).

4.2. Formular hipótesis

I H_0 (hipótesis nula): La variable continua no influye en la ocurrencia de la variable categórica.

II H_1 (hipótesis alternativa): La variable continua sí influye en la ocurrencia de la variable categórica.

4.3. Método estadístico

I Aplicar regresión logística binaria, donde:
- La variable categórica es la salida (dependiente).
- La variable continua es la entrada (independiente).

II La fórmula de la regresión logística es:

$$p(Y = 1 \mid X) = \frac{1}{1+e^{-(\beta_0+\beta_1 X)}}$$

Donde:

- $p(Y = 1 \mid X)$: probabilidad de que ocurra la categoría de interés.
- β_0: intercepto.
- β_1: coeficiente que mide el efecto de la variable continua X.

III El coeficiente β1 se evalúa para determinar si la variable continua es un predictor significativo de la variable categórica.

4.4. Ajustar el modelo

I Calcular el coeficiente β y su valor p para probar la significancia estadística.

II Obtener la odds ratio ($OR = e^{\beta_1}$)

Nota: OR se interpreta como:
- OR = 0: no cambia la probabilidad (no hay efecto)
- OR > 1: por cada unidad que aumenta la variable continua, aumentan las odds de que ocurra la categoría.
- OR < 1: por cada unidad que aumenta la variable continua, disminuyen las odds de que ocurra la categoría.

En otras palabras:
- Si $\beta_1 = 0 \rightarrow e^0 = 1$: no cambia la probabilidad (no hay efecto).
- Si $\beta_1 > 0 \rightarrow e^0 > 1$: la variable continua aumenta las odds del evento.
- Si $\beta_1 < 0 \rightarrow e^0 < 1$: la variable continua reduce las odds del evento.

Ejemplos:
- $\beta_1 = 0 \rightarrow OR = 1$:
  - La variable continua X no tiene efecto .
- $\beta_1 = 0.1 \rightarrow OR = 1.105$:
  - Cada unidad extra en X aumenta las odds en 10.5%.
- $\beta_1 = -0.2 \rightarrow OR = 0.82$:
  - Cada unidad extra en X reduce las odds en 18%.

III Concluir:
- Si p < 0.05 → la variable continua sí predice la ocurrencia de la categórica.
- Si p ≥ 0.05 → no hay evidencia suficiente para afirmar que la continua predice la categórica.

4.5. Graficar los hallazgos

I Boxplot o violin plot para comparar la distribución de la variable continua entre categorías (exploración inicial).

II Curva logística ajustada:

- Eje X = variable continua.
- Eje Y = probabilidad estimada de pertenecer a la categoría (ej. ser fumador).
- Incluir bandas de confianza al 95% alrededor de la curva.

---

5) EVALUACIÓN ESTADÍSTICA INTEGRAL DE UNA CAMPAÑA DE MARKETING

Dataset: *Customer Personality Analysis (iFood – Kaggle)*

Contexto del Problema

Una empresa de productos de consumo masivo desea evaluar el impacto de sus campañas de marketing en el comportamiento de compra de sus clientes. Utilizando el dataset *Customer Personality Analysis*, se cuenta con información detallada sobre el gasto de cada cliente en distintas categorías de productos (vinos, frutas, carne, pescado, dulces y productos premium), así como variables sociodemográficas y la variable Response, que indica si el cliente aceptó la campaña más reciente.

La empresa desea responder las siguientes preguntas:

1. ¿Existen diferencias significativas en el gasto por categoría entre los clientes que aceptaron la campaña y aquellos que no la aceptaron?
2. ¿Está el nivel de ingreso (Income) asociado con el gasto en cada categoría de producto?
3. ¿La probabilidad de aceptar la campaña depende del nivel educativo o del estado civil del cliente?

Dado que estas preguntas implican realizar múltiples pruebas estadísticas simultáneamente, será obligatorio aplicar una corrección por comparaciones múltiples y analizar cómo cambian las conclusiones tras el ajuste.

5.1. Comparación de gasto por categoría según respuesta a campaña (6 pruebas)

Variable de grupo (binaria): *Response:*

- *Grupo 1: Response = 1 (aceptó la campaña)*
- *Grupo 0: Response = 0 (no aceptó la campaña)*

I. **Comparaciones obligatorias (6):** Para cada variable de gasto, comparar la distribución (o media) entre ambos grupos:
   - Comparar MntWines entre Response=1 vs Response=0
   - Comparar MntFruits entre Response=1 vs Response=0
   - Comparar MntMeatProducts entre Response=1 vs Response=0
   - Comparar MntFishProducts entre Response=1 vs Response=0
   - Comparar MntSweetProducts entre Response=1 vs Response=0
   - Comparar MntGoldProds entre Response=1 vs Response=0

II. **Prueba a elegir (por cada A1–A6):**
   - Si (aprox.) normalidad y varianzas razonables → t-test independiente
   - Si no hay normalidad → Mann–Whitney U

III. **En cada A1–A6 deben reportar:** medias/medianas por grupo, estadístico, p-value, tamaño de efecto (recomendado).

5.2. Correlación entre ingreso y gasto por categoría (6 pruebas)

Variable continua explicativa: *Income*
Variables respuesta (gasto por categoría): *MntWines, MntFruits, MntMeatProducts, MntFishProducts, MntSweetProducts, MntGoldProds*

I. **Correlaciones obligatorias (6):** Para cada categoría, evaluar asociación entre Income y el gasto:
   - Correlación entre Income y MntWines
   - Correlación entre Income y MntFruits
   - Correlación entre Income y MntMeatProducts
   - Correlación entre Income y MntFishProducts
   - Correlación entre Income y MntSweetProducts
   - Correlación entre Income y MntGoldProds

II. **Prueba a elegir (por cada B1–B6):**
   - Relación aproximadamente lineal y variables ~ normales → **Pearson**
   - Si no hay normalidad o hay outliers fuertes/no linealidad → **Spearman**

III. **Por cada correlación reportar:** coeficiente (r o ρ), p-value, dirección (±), fuerza (débil/moderada/fuerte con criterio).

5.3. Asociación de Response con variables categóricas (2 pruebas mínimas)

I. **Asociación entre Response y Education (Chi-cuadrado de independencia**
   Comparar: Response (0/1) vs Education (categorías)

II. **Asociación entre Response y Marital_Status (Chi-cuadrado de independencia**
   Comparar: Response (0/1) vs Marital_Status (categorías)

I y II deben incluir: Tabla de contingencia, porcentajes, χ^2, gl, p-value, conclusión.

5.4. Corrección por múltiples pruebas (Obligatorio)

En este proyecto hay al menos:

- 6 pruebas del Bloque A
- 6 pruebas del Bloque B
- 2 pruebas del Bloque C

Total mínimo: k = 14 pruebas

I. Aplicar corrección Bonferroni a los p-values de todas las pruebas A1–A6, B1–B6, C1–C2:

$$\alpha_{ajustado} = 0.05/k$$

II. Aplicar corrección FDR (Benjamini–Hochberg) a los mismos p-values.

III. Entregar una tabla resumen:

- Nombre de prueba (A1…C2)
- p-value original
- p-value ajustado (Bonferroni)
- p-value ajustado (FDR, si aplica)
- ¿Sigue siendo significativa? (sí/no)

5.5. Integrar hallazgos:

- ¿En qué categorías de gasto hay evidencia de diferencias por Response?
- ¿Qué categorías se asocian con Income?
- ¿Education o Marital_Status se asocian con Response?
- ¿Qué cambió después de aplicar corrección por múltiples pruebas?
- Recomendación final para la empresa.